# 扩展索引结构

上一章介绍了不少有关查询Elasticsearch的知识,展示了如何在Elasticsearch中选择返回字段,并说明了查询的工作方式。除此之外,我们还了解到可用的基本查询以及过滤数据的方法,如何高亮文档中的匹配文字,如何验证查询、复合查询,以及如何对数据排序。这一章的主要内容如下:

- □ 索引树型结构数据;
- □ 索引非扁平数据;
- □ 在可能情况下修改索引结构;
- □ 使用嵌套文档索引关系型数据;
- □ 使用主从功能索引关系型数据。

### 4.1 索引树形结构

树型结构随处可见。如果开发一个商店应用程序,可能会需要类别。看看文件系统,文件和目录以树状结构排列。本书也呈树型:章节包含各种主题,而主题又划分为副主题。想象得出,Elasticsearch也能够索引树状结构。让我们看看如何通过path analyzer浏览这种数据类型。

#### 4.1.1 数据结构

首先,通过以下代码创建一个简单的索引结构:

```
"mappings" : {
    "category" : {
      "properties" : {
        "category" : {
          "type" : "string",
          "fields" : {
            "name" : { "type" : "string",
                        "index" : "not_analyzed" },
            "path" : { "type" : "string",
                        "analyzer" : "path_analyzer",
                        "store" : true }
          }
        }
      }
   }
 }
} '
```

可以看到,我们创建了一个类型: category。我们将使用它在树型结构中存储文档位置的信息。想法很简单,可以用与在硬盘里显示文件和目录完全相同的方式,以路径的形式显示文档位置。例如,在一家汽车店中可以有如下路径: /cars/passenger/sport、/cars/passenger/camper,或者/cars/delivery\_truck/。需要用三种方式对这个路径建立索引。我们将使用未经额外处理的name字段,以及一个使用定义的path\_analyzer处理的path字段,也保留原始值以方便搜索。

### 4.1.2 分析

现在,让我们看看Elasticsearch在分析的过程中如何处理类别路径。为此,运用5.7节中描述的分析API,执行以下命令:

```
curl -XGET 'localhost:9200/path/_analyze?field=category.path&pretty' -d '/cars/passenger/sport'
Elasticsearch返回的结果如下所示:
```

```
"tokens" : [ {
    "token" : "/cars",
    "start_offset" : 0,
    "end_offset" : 5,
    "type" : "word",
    "position" : 1
}, {
    "token" : "/cars/passenger",
    "start_offset" : 0,
    "end_offset" : 15,
    "type" : "word",
    "position" : 1
}, {
    "token" : "/cars/passenger/sport",
```

```
"start_offset" : 0,
    "end_offset" : 21,
    "type" : "word",
    "position" : 1
    } ]
```

可以看到, Elasticsearch把类别路径/cars/passenger/sport处理并分解成三个标记。归功于此, 我们很容易通过词条过滤器找到每个属于指定类别或子类别的文档。举例如下:

```
{
  "filter" : {
    "term" : { "category.path" : "/cars" }
  }
}
```

注意,我们还在索引中建立了category.name字段的原始值,便于直接找到特定路径的文档,略过层次结构更深的文档。

# 4.2 索引非扁平数据

并非所有数据都是扁平数据,就像到目前为止本书使用的所有数据。如果我们构建使用 Elasticsearch的系统,应创建有利于Elasticsearch的结构。结构不总是扁平的,因为并非所有用例 都允许这样操作。让我们看看如何使用完全结构化的JSON对象创建映射。

### 4.2.1 数据

假定有如下数据(存储于structured\_data.json文件中):

```
"book" : {
    "author" : {
        "name" : {
            "firstName" : "Fyodor",
            "lastName" : "Dostoevsky"
      }
    },
    "isbn" : "123456789",
    "englishTitle" : "Crime and Punishment",
    "year" : 1886,
    "characters" : [
        {
            "name" : "Raskolnikov"
      },
      {
            "name" : "Sofia"
      }
    ],
```

```
"copies" : 0 } }
```

可以看到,在上面的代码中,数据并非是扁平的;它包含了数组和嵌套对象。如果要运用目前为止学到的知识创建映射,我们不得不将数据变为扁平。然而,Elasticsearch允许文档中存在一定程度的结构,可以创建能够处理上述示例的映射。

#### 4.2.2 对象

上述示例显示了结构化的JSON文档。可以看到,示例文档的根对象是book,具备一些额外、简单的属性,比如englishTitle。它们将以正常字段的形式索引。此外,还有characters数组类型,这一点将在接下来的段落中讨论。现在,让我们关注author对象,可以看到,它还嵌套了另一个有两个属性firstName和lastName的对象name。

#### 4.2.3 数组

我们已经使用过数组类型的数据,但未详细讨论。默认情况下,在Lucene中的所有字段都是多值的,因此在Elasticsearch中也是一样,这意味着它们可以存储多个值。为了索引这些字段,我们使用JSON数组类型,嵌套在中括号[]中。上述示例里,我们对book中的characters使用了数组类型。

# 4.2.4 映射

为索引数组,只需要在数组名称中指定字段的属性。因此,在我们的例子中,可添加以下映射来索引characters的数据:

```
"characters" : {
   "properties" : {
       "name" : {"type" : "string", "store" : "yes"}
   }
}
```

没什么特殊的,仅仅在数组名称(在例子中为characters)中嵌套了properties节点, 并定义字段。由于前面的映射,我们在索引中获得多值字段characters.name。

同样,对于对象author,使用数据中同样的名称,除了properties部分,我们还添加了type属性并设置值为object,告知Elasticsearch应期待一个对象类型。在对象author中嵌套了对象name,因此author字段的映射如下所示:

```
"author" : {
   "type" : "object",
```

```
"properties" : {
    "name" : {
        "type" : "object",
        "properties" : {
            "firstName" : {"type" : "string", "index" : "analyzed"},
            "lastName" : {"type" : "string", "index" : "analyzed"}
        }
    }
}
```

firstName和lastName字段在索引中体现为author.name.firstName和author.name.lastName。

其余字段为简单的核心类型,2.2节已经讨论过,这里不再赘述。

#### 最终映射

所以,我们的映射文件structured\_mapping.json的最终映射如下所示:

```
"book" : {
    "properties" : {
      "author" : {
        "type" : "object",
        "properties" : {
          "name" : {
            "type" : "object",
            "properties" : {,
              "firstName" : {"type" : "string", "store": "yes"},
              "lastName" : {"type" : "string", "store": "yes"}
          }
        }
      "isbn" : {"type" : "string", "store": "yes"},
      "englishTitle" : {"type" : "string", "store": "yes"},
      "year" : {"type" : "integer", "store": "yes"},
      "characters" : {
        "properties" : {
          "name" : {"type" : "string", "store": "yes"}
       }
      "copies" : {"type" : "integer", "store": "yes"}
   }
 }
}
```

可以看到,所有字段中store的属性值均设置为yes。这只是为了向你展示所有字段都可以 正常索引。

# 4.2.5 向Elasticsearch发送映射

现在,映射已经完成,我们可测试确认其是否有效。这次将使用一种稍微不同的技术来创建索引和映射。首先,使用以下命令行创建library索引:

```
curl -XPUT 'localhost:9200/library'
```

接着,使用以下命令行,将映射发送至book类型:

```
curl -XPUT 'localhost:9200/library/book/_mapping' -d @structured_mapping.
json
```

现在,可使用以下命令行索引我们的示例数据:

curl -XPOST 'localhost:9200/library/book/1' -d @structured\_data.json

### 4.2.6 动态还是非动态

我们知道,Elasticsearch是无模式的,这意味着不必创建前面的映射就可索引数据。Elasticsearch的动态行为默认是打开的,但可能想在索引的某些部分把它关掉。为此,可为指定字段增加属性dynamic,将值设置为false,该属性应该设置在与非动态对象的type属性相同的级别上。举例来说,如果我们希望对象author和name为非动态,应该将映射文件的相关部分修改成类似下面这样:

```
"author" : {
  "type" : "object",
  "dynamic" : false,
  "properties" : {
      "type" : "object",
      "dynamic" : false,
      "properties" : {
            "firstName" : {"type" : "string", "index" : "analyzed"},
            "lastName" : {"type" : "string", "index" : "analyzed"}
      }
    }
}
```

应记住,为此类对象增加新字段时,应更新映射。



你也可以在elasticsearch.yml配置文件中添加index.mapper.dynamic属性,将值设置为false,关掉动态映射功能。

## 4.3 使用嵌套对象

某些情况下嵌套对象可以很方便。基本上,通过使用嵌套对象,Elasticsearch允许我们连接一个主文档和多个附属文档。主文档及嵌套文档一同被索引,放置于索引的同一段上(实际在同一块上),确保为该数据结构获取最佳性能。更改文档也是一样的,除非使用更新API,你需要同时索引父文档和其他所有嵌套文档。



如果想阅读更多Lucene中嵌套对象的工作方式,可参考迈克·麦坎德利斯(Mike McCandless)的博客,链接如下: http://blog.mikemccandless.com/2012/01/searching-relational-content-with.html。

现在,我们来看示例。假设有一个服装店,需要存储每件T恤的尺寸和颜色,那么,标准的、非嵌套映射将类似于以下的代码(存储于cloth.json中):

```
{
  "cloth" : {
    "properties" : {
        "name" : {"type" : "string"},
        "size" : {"type" : "string", "index" : "not_analyzed"},
        "color" : {"type" : "string", "index" : "not_analyzed"}
    }
}
```

假设仅有一件XXL的红色T恤和一件XL的黑色T恤,示例文档将类似于以下代码:

```
{
  "name" : "Test shirt",
  "size" : [ "XXL", "XL" ],
  "color" : [ "red", "black" ]
}
```

然而,这个数据结构有个问题:假使客户要在商店搜索XXL黑色T恤,会产生什么结果?运行以下查询来检查(假设我们已使用映射创建索引并在其中建立了示例文档):

我们不应该得到结果,对吧?但事实上,Elasticsearch返回了如下文档:

这是因为,经过比对文档,在size字段和color字段上有我们需要的值。当然,这不是我们想要的。因此,修改映射,使用嵌套对象来分离color和size。最终的映射看起来如下所示(我们把这些映射存到cloth nested.json文件中):

```
{
  "cloth" : {
    "properties" : {
        "name" : {"type" : "string", "index" : "analyzed"},
        "variation" : {
        "type" : "nested",
        "properties" : {
        "size" : {"type" : "string", "index" : "not_analyzed"},
        "color" : {"type" : "string", "index" : "not_analyzed"}
     }
    }
}
```

可以看到,我们在cloth类型中引入了新对象variation,它是嵌套的(type属性设置为 nested),表示想为嵌套文档建立索引。现在修改文档,添加variation对象,其中有两个属性: size和color。示例产品将如下所示:

组织文档结构,以便每个尺寸及其匹配颜色成为一个独立文档。然而,如果执行之前的查询,

将无任何文档返回。这是因为,对于嵌套文件,需要使用专门的查询。因此,查询如下(当然,我们已经再次创建了索引和类型):

现在,上述查询将无法返回索引中的文档,因为无法找到尺寸XXL且颜色为黑色的嵌套文档。这里简单讨论一下我们的查询,可以看到,我们使用nested查询来查询嵌套文档。path属性指定了嵌套对象的名称(可以使用多个名称)。nested类型包括了一个标准查询部分。应注意的是,在嵌套对象中为字段名称指定完整的路径,在多级嵌套中很方便操作(这也是可能的)。



如果你想在嵌套对象的基础上过滤数据,可使用嵌套过滤器,它具备与嵌套 查询相同的功能。更多相关信息,请参阅3.5节。

### 评分与嵌套查询

在查询过程中处理嵌套文档时,有一个附加属性。除path属性外,还有个score\_mode属性,它允许我们定义如何从嵌套查询中计算得分。在Elasticsearch中可将此属性设置为如下值。

- □ avg: 这是默认值。使用这个值时,Elasticsearch可在指定的嵌套查询中计算出平均值。 该平均值包含在主查询的得分中。
- □ total: score\_mode属性设置为此值时, Elasticsearch可对每个嵌套查询的得分求和。该值包含在主查询的得分中。
- □ max: score\_mode属性设置为此值时, Elasticsearch可得出嵌套查询的最高得分。该值包含在主查询的得分中。
- □ none: score\_mode属性设置为此值时, Elasticsearch不计算嵌套查询的得分。

# 4.4 使用父子关系

上一节已讨论了索引嵌套文档及其父文档的能力。然而,即使嵌套文档在索引中是作为独立文档检索的,除非使用更新API,否则还是无法更改单个嵌套文档。而在Elasticsearch中,我们可利用父子关系操作。请看以下内容。

### 4.4.1 索引结构和数据索引

在此,参考之前讨论嵌套文档时使用的示例:假想的服装店。然而我们希望的是:在每次变更后,无需索引整个文档即可更新尺寸和颜色。

#### 1. 父文档映射

在父文档中, name是我们需要的唯一字段。因此, 在shop索引中创建cloth类型, 执行如下命令:

```
curl -XPOST 'localhost:9200/shop'
curl -XPUT 'localhost:9200/shop/cloth/_mapping' -d '{
    "cloth" : {
        "properties" : {
            "name" : {"type" : "string"}
        }
    }
}'
```

#### 2. 子文档映射

为创建子文档映射,要在\_parent属性中添加父类型的名称,在我们的示例中为cloth。因此,创建类型variation的命令行将如下所示:

```
curl -XPUT 'localhost:9200/shop/variation/_mapping' -d '{
    "variation" : {
        "_parent" : { "type" : "cloth" },
        "properties" : {
            "size" : {"type" : "string", "index" : "not_analyzed"},
            "color" : {"type" : "string", "index" : "not_analyzed"}
        }
    }
}
```

我们无需指定连接父子文档的字段,因为默认情况下Elasticsearch会使用唯一标识符。如前面相关章节所述,唯一标识符以默认的形式存在于索引中。

#### 3. 父文档

现在,我们来索引父文档。操作很简单,只要执行索引命令,示例如下:

```
curl -XPOST 'localhost:9200/shop/cloth/1' -d '{
   "name" : "Test shirt"
}'
```

上述命令中,我们指定的文档标识符为1。

#### 4. 子文档

为索引子文档,需要使用parent参数提供父文档的相关信息,将该参数设置为父文档的标识符。所以,为索引父文档中的两个子文档,执行下面的命令:

```
curl -XPOST 'localhost:9200/shop/variation/1000?parent=1' -d '{
    "color": "red",
    "size": "XXL"
}'

同样, 执行如下命令行索引第二个子文档:
curl -XPOST 'localhost:9200/shop/variation/1001?parent=1' -d '{
    "color": "black",
    "size": "XL"
}'
```

这样,我们索引了两个附加文档,它们是新类型,但是我们已为其指定标识符为1的父文档。

#### 4.4.2 查询

我们已经索引了数据,现在需要恰当的查询来匹配拥有子文档数据的文档。当然,也可针对 子文档来执行查询并检测其父文档是否存在。然而要注意的是,针对父文档执行查询时,子文档 将无法返回,反之亦然。

#### 1. 查询子文档中的数据

如果要寻找XXL号的红色衣服,可以运行如下命令行:

查询很简单。类型has\_child告知Elasticsearch我们想在子文档中搜索。为了指定感兴趣的子类型,指定type属性为子类型的名称。然后用一个标准的bool查询(已经讨论过),查询的结果仅包含父文档,示例如下:

```
{
    (...)
    "hits" : {
        "total" : 1,
        "max_score" : 1.0,
        "hits" : [ {
            "_index" : "shop",
            "_type" : "cloth",
            "_id" : "1",
            "_score" : 1.0, "_source" : { "name" : "Test shirt" }
        } ]
    }
}
```

● top\_children查询

除has\_child查询之外, Elasticsearch还公开了top\_children查询,它查询子文档但返回 父文档。此查询可针对特定数量的子文档,示例如下:

```
{
   "query" : {
     "top_children" : {
        "type" : "variation",
        "query" : {
            "term" : { "size" : "XXL" }
        },
        "score" : "max",
        "factor" : 10,
        "incremental_factor" : 2
   }
}
```

上述查询首先在100个子文档中运行(factor乘以size的默认参数10)。如果找到10个父文档(因为默认size的参数值为10),这些文档将返回并结束查询。然而,如果返回的父文档数量较少,且尚有子文档未经查询,那么另外20个子文档将被查询(incremental\_factor参数乘以size),直到找到规定数量的父文档或者所有子文档查询结束为止。

top\_children查询通过使用score参数指定得分的计算方式,可能的参数值包括: max(所有子查询得分的最大值)、sum(所有子查询得分的总和)或avg(所有子查询得分的平均值)。

#### 2. 查询父文档中的数据

如果想要返回与父文档中指定数据匹配的子文档,可使用类似于has\_child的查询: has\_parent。然而,我们用父文档类型的值指定parent\_type属性,而不是type属性。这么 这个查询将返回索引的子文档,而不是父文档:

```
curl -XGET 'localhost:9200/shop/ search?pretty' -d '{
  "query" : {
    "has_parent" : {
      "parent_type" : "cloth",
      "query" : {
        "term" : { "name" : "test" }
    }
  }
} '
Elasticsearch的响应如下所示:
{
  (...)
  "hits" : {
    "total" : 2,
    "max_score" : 1.0,
    "hits" : [ {
      "_index" : "shop",
      " type" : "variation",
      "_id" : "1000",
      "_score" : 1.0, "_source" : {"color" : "red", "size" : "XXL"}
    }, {
      " index" : "shop",
      "_type" : "variation",
      " id" : "1001",
      "_score" : 1.0, "_source" : {"color" : "black", "size" : "XL"}
    } ]
  }
}
```

### 4.4.3 父子关系和过滤

如果想要将父子查询作为过滤器使用,可以用过滤器has\_child和has\_parent,它们具备了与has\_child和has\_parent查询相同的功能。实际上,Elasticsearch将那些过滤器封装为常数得分查询,使其可作为查询使用。

### 4.4.4 性能考虑

使用Elasticsearch父子的功能时,必须注意它的性能影响。需要记住的第一件事是父子文档需要存储在相同的分片中,查询才能够工作。如果单一父文档有大量的子文档,可能导致分片上的文档数量不平均。因此,其中的一个节点的性能会降低,造成整个查询速度变慢。另外,请记住、比起查询无任何关联的文档,父子查询的速度较慢。

第二个非常重要的事情是,执行has\_child等查询时,Elasticsearch需要预加载并缓存文档标识符。这些标识符将存储在内存中,必须确保Elasticsearch有足够的内存。否则,你将得到OutOfMemory异常,节点或整个集群将无法运作。

最后,我们提到过,首次查询将花一定时间预加载和缓存文档标识符。为了提升首次查询父子关系文档的性能,可以使用预热API。关于如何在Elasticsearch中添加预热查询,请参考8.5节。

# 4.5 使用更新 API 修改索引结构

前面的章节讨论过如何创建索引映射和索引数据。如果你已经创建了映射和索引数据,想要修改索引的结构,应该怎么办?在某种程度上这是可行的。例如,默认情况下索引一个带新字段的文档,Elasticsearch会将该字段增加到索引结构中。现在看看如何手动修改索引结构。

#### 4.5.1 映射

假设我们的users索引有以下映射,存储于user.json文件中:

```
{
    "user" : {
        "properties" : {
            "name" : {"type" : "string"}
        }
    }
}
```

可以看到,它很简单,只有一个属性保存用户名。现在,让我们创建一个名为users的索引,并使用上面的映射创建自己的类型。为此,运行以下命令:

```
curl -XPOST 'localhost:9200/users'
curl -XPUT 'localhost:9200/users/user/_mapping' -d @user.json
```

如果一切正常,我们的索引和类型便创建好了。现在,添加一个新字段到映射中去。

# 4.5.2 添加一个新字段

为了说明如何为映射添加新字段,我们假设要为每个存储的用户添加一个电话号码。为此,需要将HTTP PUT命令发送到带有合适主体的/index\_name/type\_name/\_mapping REST端点,该主体中包含我们的新字段。例如,为添加phone字段,执行以下命令:

```
curl -XPUT 'http://localhost:9200/users/user/_mapping' -d '{
   "user" : {
     "properties" : {
        "phone" : {"type" : "string",
```

```
"store": "yes",
"index" : "not_analyzed"}
```

同样,如果一切正常,新字段便添加到我们的索引结构中去了。为了确保一切正常,可以运 行HTTP GET请求到\_mapping端点; Elasticsearch将返回适当的映射。在索引users中获得user 类型映射的示例命令如下所示:

curl -XGET 'localhost:9200/users/user/\_mapping?pretty'



在现有类型中添加新字段后,需要再次对所有文档进行索引,因为 Elasticsearch不会自动更新。这很关键,可以使用初始数据源或从\_source 字段中获得初始数据并再次索引。

### 4.5.3 修改字段

现在,我们的索引结构包含两个字段: name和phone。我们索引了一些数据,但之后又决定 搜索phone字段,并希望更改index属性,从not\_analyzed改为analyzed,为此,执行以下命令:

```
curl -XPUT 'http://localhost:9200/users/user/_mapping' -d '{
  "user" : {
    "properties" : {
      "phone" : {"type" : "string",
                 "store" : "yes",
                 "index" : "analyzed"}
    }
 }
```

执行上面的命令行后, Elasticsearch返回以下输出:

{"error": "MergeMappingException[Merge failed with failures {[mapper [phone] has different index values, mapper [phone] has different 'norms. enabled' values, mapper [phone] has different tokenize values, mapper [phone] has different index\_analyzer]}]","status":400}

这是因为无法将not analyzed字段更改为analyzed。不仅如此,在大部分情况下字段映 射是无法更新的。这是好事,因为如果我们可以更改这样的设置,会让Elasticsearch和Lucene混 乱。假设已经有很多文档带有设置为not\_analyzed的phone字段,将这些设置更改为 analyzed, Elasticsearch将无法更改已索引的文档,但已经分析的查询将以不同的逻辑处理,那 么我们就无法正确查找数据。

我们在此将提及一些操作,举例说明哪些是禁止的,哪些是允许的。如下修改是安全的:

- □ 增加新的类型定义;
- □ 增加新的字段;
- □增加新的分析器。

而以下修改是不允许或是无法实现的:

- □ 更改字段类型(如将文本改为数字);
- □ 更改"存储到"字段为不存储, 反之亦然;
- □ 更改索引属性的值;
- □更改已索引文档的分析器。

注意一点,上述允许和不允许的操作没有涵盖更新API的全部可能性,你必须实际操作以验证更新是否可行。



如果你想忽略冲突并设置新映射,可设置ignore\_conflicts的参数值为true, Elasticsearch将会重写映射。带有额外参数的命令行如下:

curl -XPUT 'http://localhost:9200/users/user/\_mapping?
ignore\_conflicts=true' -d '...'

### 4.6 小结

这一章讲述了如何使用Elasticsearch索引树型结构,索引非扁平数据,以及修改已创建的索引结构。最后,介绍了如何使用嵌套文档及Elasticsearch中的父子功能来处理关系型数据。

下一章的重点是更高效地搜索,我们将看到Apache Lucene得分的工作方式及其重要性;学习使用Elasticsearch的函数得分查询,用函数以及提供的脚本功能来调整不同文档的重要性,使用不同的语言来搜索,并讨论索引时加权什么时候有意义。下一章将使用同义词匹配具有相同含义的单词,介绍检测文档被查询到的原因。最后,使用加权来影响查询,并解释Elasticsearch的得分计算。